

Titulo

Debany Jazmín Hernández Camacho

Centro de Investigación en Matemáticas · Maestría en Matemáticas Aplicadas
debany.hernandez@cimat.mx

1 ■ Introducción

La segmentación de clientes es una herramienta fundamental dentro del análisis moderno de datos financieros. En particular, las instituciones crediticias requieren identificar patrones de comportamiento que permitan distinguir entre individuos con bajo riesgo, perfiles estables y usuarios con una mayor probabilidad de presentar dificultades en el pago de sus obligaciones. Esta necesidad surge de la alta heterogeneidad de los clientes: cada persona combina distintos niveles de ingreso, uso del crédito, historial de morosidad y carga financiera, lo que hace insuficiente cualquier clasificación basada únicamente en una o dos variables.

En este proyecto se desarrolla un análisis integral de segmentación utilizando el conjunto de datos **Give Me Some Credit**, el cual contiene información financiera y demográfica de aproximadamente 150,000 individuos. El objetivo general es construir perfiles homogéneos de clientes a partir de sus características crediticias, sin emplear una variable objetivo o etiquetas previas. Para ello se utilizan exclusivamente técnicas de aprendizaje no supervisado, lo que permite dejar que los datos revelen sus propias estructuras internas.

El proceso metodológico combina 3 elementos centrales:

- ♦ una etapa detallada de preprocesamiento para limpiar, imputar y estabilizar las variables, dado que la base de datos presenta altas asimetrías, valores extremos y valores faltantes;
- ♦ una reducción de dimensionalidad mediante Análisis de Componentes Principales (PCA), con el fin de capturar la estructura esencial de variabilidad del conjunto;
- ♦ un análisis de agrupamiento utilizando K-Means sobre el espacio reducido por PCA.

Más allá del mero cálculo de clusters, el propósito de este estudio es interpretar cada uno de los perfiles resultantes desde una perspectiva financiera, buscando responder lo siguiente, ¿qué caracteriza a los clientes menos riesgosos?, ¿qué patrones de endeudamiento o morosidad distinguen a los grupos más vulnerables?, ¿cómo se relacionan variables como ingresos, utilización de crédito y número de dependientes con el comportamiento crediticio? El énfasis está puesto en describir estos perfiles de forma clara y útil, de modo que el agrupamiento tenga un sentido práctico dentro del contexto del riesgo financiero.

Así, este trabajo no solo construye una segmentación estadísticamente coherente, sino que busca comprender qué factores dan forma a los distintos tipos de clientes. El resultado es un análisis que combina técnica, interpretación y una visión aplicada de la Ciencia de Datos dentro del ámbito del endeudamiento personal.

2 ■ Exploración inicial de los datos

El análisis se basa en el conjunto de datos *Give Me Some Credit*, el cual contiene información financiera y demográfica a nivel individual. Cada fila corresponde a un cliente distinto y resume su situación crediticia en un momento específico, a partir de un conjunto de variables cuantitativas relacionadas con ingreso, endeudamiento, uso del crédito y comportamiento de pago. Para este trabajo se utiliza la versión depurada del archivo `cs_training.csv`, que incluye aproximadamente 150,000

observaciones. Todas las variables empleadas en el análisis son numéricas, lo que facilita el uso de técnicas de reducción de dimensionalidad y agrupamiento basadas en distancias. La estructura general del conjunto puede verse como una matriz de tamaño $n \times p$, donde n es el número de clientes y p el número de variables consideradas.

La base de datos original contiene una variable binaria asociada a morosidad severa a dos años (SeriousDlqin2yrs), así como diez predictores numéricos que describen hábitos de uso del crédito, niveles de deuda, historial de atrasos y características demográficas simples (edad y número de dependientes). En este proyecto, dicha variable binaria se utiliza únicamente como información contextual y no forma parte del proceso de agrupamiento, que se construye de manera completamente no supervisada.

En la Tabla 1 se resumen las variables principales utilizadas, indicando para cada una su tipo de dato y una breve descripción de su significado dentro del contexto financiero del problema.

Cuadro 1. Descripción de las variables de la base de datos

Variable	Tipo	Descripción
SeriousDlqin2yrs	Binaria (0/1)	Indica si el cliente incurrió en morosidad grave (90+ días de atraso) en los próximos dos años.
RevolvingUtilizationOfUnse	N Numérica continua (≥ 0)	Proporción de utilización de las líneas de crédito no aseguradas (por ejemplo, tarjetas de crédito). Valores cercanos a 1 indican uso al límite.
age	N Numérica discreta	Edad del cliente en años.
NumberOfTime30-59DaysPastD	N Numérica discreta (≥ 0)	Número de veces con atrasos de 30–59 días, sin caer en morosidad severa.
DebtRatio	N Numérica continua (≥ 0)	Razón entre el total de pagos mensuales de deuda y gastos, respecto al ingreso mensual declarado. Mide la carga financiera relativa del cliente.
MonthlyIncome	N Numérica continua (≥ 0)	Ingreso mensual declarado por el cliente.
NumberOfOpenCreditLinesAnd	N Numérica discreta (≥ 0)	Número de líneas de crédito y préstamos abiertos (tarjetas, préstamos personales, etc.).
NumberOfTimes90DaysLate	N Numérica discreta (≥ 0)	Número de atrasos de 90 días o más. Indicador de morosidad severa.
NumberRealEstateLoansOrLin	N Numérica discreta (≥ 0)	Número de préstamos inmobiliarios (por ejemplo, hipotecas).
NumberOfTime60-89DaysPastD	N Numérica discreta (≥ 0)	Número de veces que el cliente ha estado entre 60–89 días de atraso, sin caer en estados peores.
NumberOfDependents	N Numérica discreta (≥ 0)	Cantidad de dependientes económicos del cliente.

3 ■ Metodología

En esta etapa, el análisis se desarrolló siguiendo un flujo de trabajo estructurado que permite transformar la base de datos original en una representación más estable y útil para descubrir patrones. Dado que la información financiera suele presentar irregularidades importantes, distribuciones muy sesgadas, outliers y escalas poco comparables, el primer paso consistió en preparar cuidadosamente las variables para asegurar que todas aportaran de manera equilibrada al modelo.

Una vez obtenidos los datos en condiciones adecuadas, se aplicó una reducción de dimensionalidad mediante Análisis de Componentes Principales (PCA), con el fin de concentrar la mayor parte de la variabilidad del conjunto en unas cuantas dimensiones interpretables. Este espacio reducido facilita tanto la visualización como la separación de los individuos en grupos más homogéneos.

Finalmente, sobre la representación generada por PCA se llevó a cabo un proceso de agrupamiento no supervisado mediante K-Means, buscando identificar perfiles de clientes con características financieras similares. Las etapas que siguen describen con detalle cada una de estas fases: desde el preprocesamiento hasta la construcción de los clusters finales.

3.1 ■ Preprocesamiento

El preprocesamiento fue una etapa esencial debido a la presencia de outliers, datos faltantes y distribuciones altamente asimétricas, todas características comunes en información financiera. El objetivo de esta fue obtener un conjunto de datos estable, consistente y adecuado para la aplicación de técnicas basadas en distancia, especialmente PCA y K-Means.

En primer lugar, se eliminaron los registros duplicados y un único caso con edad igual a 0, valor imposible en el contexto de estudio. Posteriormente, se atendieron los valores faltantes: `MonthlyIncome` presentaba aproximadamente 5,400 observaciones vacías, que fueron imputadas mediante la mediana de la distribución, una estrategia adecuada dada su fuerte asimetría. Para `NumberOfDependents` se empleó la moda, pues la mayoría de los clientes declara entre cero y dos dependientes.

Antes de aplicar transformaciones adicionales, se examinó la matriz de correlación de las variables financieras. Esta permitió identificar que, si bien existen asociaciones relevantes entre ciertos pares por ejemplo, entre las distintas medidas de morosidad o entre el nivel de ingreso y la actividad crediticia, muchas de las correlaciones son de magnitud moderada o baja. Esta estructura sugiere que las variables capturan dimensiones distintas del comportamiento financiero y que ninguna domina por completo a las demás. El patrón observado respalda el uso de una técnica de reducción de dimensionalidad como PCA, capaz de sintetizar información dispersa en múltiples sentidos de variación.




Figura 1. Matriz de correlación del conjunto de variables financieras.

Un análisis exploratorio reveló la existencia de valores extremadamente grandes en variables como `RevolvingUtilizationOfUnsecuredLines` y `DebtRatio`. Estos valores, aunque plausibles en ciertos contextos de endeudamiento, afectan de manera desproporcionada a métodos sensibles a la escala. Para controlar este efecto sin eliminar observaciones completas, se aplicó "winsorización": `RevolvingUtilizationOfUnsecuredLines` fue truncada en su percentil 99, mientras que `DebtRatio` se truncó en el percentil 99.5 debido a la presencia de outliers particularmente severos.

Una vez estabilizadas las distribuciones, todas las variables fueron estandarizadas mediante *StandardScaler*. Esta normalización garantiza que cada variable contribuya en igualdad de condiciones al análisis, evitando que aquellas con rangos grandes dominen los componentes principales o los centroides del clustering. El resultado final de esta etapa fue un conjunto limpio, sin valores faltantes, con outliers suavizados y todas las variables expresadas en una escala comparable.

3.2 ■ Reducción de dimensionalidad mediante PCA

Una vez que las variables estuvieron depuradas y estandarizadas, se aplicó un Análisis de Componentes Principales (PCA) con el objetivo de sintetizar la información esencial del conjunto en un número reducido de dimensiones. Esta técnica permite identificar combinaciones lineales de las variables originales que concentran la mayor parte de la variabilidad total, lo cual resulta especialmente útil cuando se trabaja con datos altamente correlacionados o con estructuras difíciles de visualizar directamente.

El PCA se estimó inicialmente sin fijar un número específico de componentes, permitiendo analizar la proporción de varianza capturada por cada dirección principal. La Figura 2 muestra tanto la varianza explicada individual como la acumulada. A partir de este análisis, se observó que los primeros seis componentes concentran aproximadamente el 87.6 % de la variabilidad total, proporción suficiente para conservar la estructura global de los datos sin incluir dimensiones dominadas por ruido o fluctuaciones menores. En consecuencia, el análisis posterior se realizó únicamente sobre este espacio reducido de seis dimensiones.




Figura 2. Varianza explicada por cada componente principal y varianza acumulada.

Además de la reducción en la complejidad, el PCA facilita una interpretación cualitativa de los patrones subyacentes. El examen de los *loadings* mostró que ciertos componentes están fuertemente asociados al nivel general de endeudamiento, mientras que otros reflejan principalmente la morosidad, la actividad crediticia o la capacidad económica. Estas relaciones permiten entender qué factores impulsan las diferencias entre los individuos y proporcionan un marco interpretativo sólido para el paso final de agrupamiento.

En conjunto, el uso de PCA no solo mejora la estabilidad del modelo de clustering, sino que también aporta una representación más clara y manejable de la estructura del conjunto de datos.

3.3 ■ Construcción del modelo de agrupamiento

Una vez definido el espacio reducido mediante PCA, el siguiente paso fue construir el modelo de agrupamiento sobre las seis componentes principales. Para decidir cuántos grupos utilizar, se evaluaron distintos valores de k en el rango de 2 a 10 aplicando el algoritmo K-Means sobre el DataFrame transformado (`df_pca`). Para cada valor de k se calcularon dos cantidades: la inercia (suma de distancias cuadráticas de cada punto a su centroide) y el coeficiente de Silhouette asociado a la partición obtenida.

La Figura 3 muestra el comportamiento de la inercia en función de k . Como es de esperarse, la inercia disminuye de manera monótona al aumentar el número de clusters, pero la tasa de descenso no es constante. Se observa una caída pronunciada entre $k = 2$ y $k \approx 4-6$, seguida de una zona donde la curva se aplana. Este “codo” sugiere que a partir de cinco grupos los beneficios de seguir aumentando k son marginales en términos de reducción de inercia.




Figura 3. Método del codo para distintos valores de k en el modelo K-Means.

De manera complementaria, la Figura 4 muestra el coeficiente de Silhouette promedio para los mismos valores de k . El valor más alto se obtiene en $k = 2$, lo que refleja una separación muy marcada entre dos grandes grupos de individuos. Sin embargo, a partir de $k = 3$ los valores de Silhouette se estabilizan en un rango cercano a 0.25–0.30, indicando que es posible considerar particiones más finas sin perder coherencia en la separación entre clusters. En particular, los valores alcanzados para $k = 5$ son comparables a los de otros modelos con $k > 2$, pero permiten distinguir matices adicionales en los patrones de endeudamiento y morosidad que quedarían ocultos en una segmentación demasiado gruesa.




Figura 4. Coeficiente de Silhouette promedio para k entre 2 y 10.

Con base en ambos criterios y en la interpretabilidad de los perfiles resultantes, se fijó $k = 5$ como número de clusters para el modelo final. Las etiquetas obtenidas se incorporaron posteriormente al conjunto limpio original (`df_clustering`) para formar el DataFrame `df_resultado`, que se utiliza en la sección de resultados para analizar y describir en detalle los perfiles de endeudamiento correspondientes a cada cluster.

4 ■ Resultados

Una vez ajustado el modelo de agrupamiento, el análisis se centró en caracterizar los perfiles financieros que emergen de los cinco clusters seleccionados. Para ello se emplearon tanto métricas descriptivas como visualizaciones que permiten comparar los grupos en términos de morosidad, actividad crediticia, endeudamiento y capacidad económica.

Antes de presentar las figuras principales, se realizó una inspección general de los datos proyectados en el espacio PCA y de la distribución de variables clave mediante boxplots. Estas visualizaciones confirmaron que los grupos presentan patrones distinguibles en las componentes principales y diferencias marcadas en variables como ingresos, deuda relativa y líneas de crédito abiertas. Esto proporcionó una primera evidencia de que los clusters reflejan comportamientos financieros heterogéneos.

4.1 ■ Mapa de calor de medias normalizadas

Para comparar de manera directa la posición relativa de cada grupo en todas las variables, se construyó un mapa de calor basado en medias normalizadas mediante *z-score*. La Figura 5 muestra este resumen, donde valores positivos (en tonos rojos) representan niveles por encima del promedio poblacional, mientras que valores negativos (en tonos azules) corresponden a niveles inferiores.




Figura 5. Mapa de calor de medias normalizadas (*z-score*) para las variables financieras según cluster.

El mapa de calor revela contrastes claros entre los grupos. Algunos clusters exhiben valores elevados en indicadores de morosidad, mientras que otros destacan por ingresos altos o mayor actividad crediticia. Asimismo, ciertos grupos combinan baja utilización del crédito con niveles relativamente moderados de deuda, lo que sugiere comportamientos estables. Estas diferencias estructurales confirman que el modelo captura perfiles financieros distintos y consistentes con dimensiones económicas reales.