

Segmentación de Clientes por Perfil de Endeudamiento

Aprendizaje no supervisado

Debany Jazmín Hernández Camacho

Maestría en Matemáticas Aplicadas
Centro de Investigación en Matemáticas (CIMAT)
debany.hernandez@gmail.com

Introducción a la Ciencia de Datos
Proyecto Final

Introducción

Introducción

La segmentación de clientes es una herramienta central en el análisis moderno de datos financieros, pues permite distinguir entre individuos con bajo riesgo, perfiles estables y usuarios con mayor probabilidad de presentar dificultades en el pago de sus obligaciones.

En la práctica, cada cliente combina distintos niveles de:

- ingreso,
- uso del crédito,
- historial de morosidad,
- carga financiera y número de dependientes.

Esta heterogeneidad hace insuficiente cualquier clasificación basada en pocas variables o reglas simples, y motiva el uso de métodos estadísticos capaces de descubrir estructuras más complejas directamente a partir de los datos.

Planteamiento del problema

Se trabajó con la base de datos *Give Me Some Credit*, que recopila información financiera y demográfica de aproximadamente 150,000 clientes. Cada registro resume la situación crediticia de un cliente mediante variables relacionadas con ingreso, endeudamiento, uso del crédito y comportamiento de pago.

Objetivo

- Identificar, sin etiquetas previas, **perfiles homogéneos de clientes** a partir de sus características crediticias.

Preguntas guía

- ¿Qué caracteriza a los clientes menos riesgosos?
- ¿Qué patrones de endeudamiento o morosidad distinguen los grupos más vulnerables?
- ¿Cómo se relacionan variables como ingresos, utilización de crédito y número de dependientes con el comportamiento crediticio?

Metodología

La base de datos *Give Me Some Credit* contiene 10 variables financieras y demográficas relacionadas con endeudamiento, ingreso y comportamiento de pago.

Variable	Descripción
RevolvingUtilizationOfUnsecured	Uso relativo de líneas de crédito no aseguradas.
age	Edad del cliente.
DebtRatio	Proporción entre gastos + pagos de deuda y el ingreso mensual.
MonthlyIncome	Ingreso mensual declarado.
NumberOfOpenCreditLinesAnd	Número total de cuentas y préstamos activos.
NumberRealEstateLoansOrLine	Préstamos o líneas inmobiliarias (ej. hipotecas).
NumberOfDependents	Número de dependientes económicos.
NumberOfTime30–59DaysPastDueNotWorse	Atrasos de 30–59 días.
NumberOfTime60–89DaysPastDueNotWorse	Atrasos de 60–89 días.
NumberOfTimes90DaysLate	Atrasos graves (90+ días).

Preprocesamiento


Antes de aplicar técnicas de aprendizaje no supervisado, se realizó un preprocesamiento para asegurar que las variables fueran comparables y estables.

Pasos principales:

- Eliminación de registros duplicados y del caso con edad igual a 0.
- Imputación de valores faltantes:
 - *MonthlyIncome*: mediana (distribución altamente asimétrica).
 - *NumberOfDependents*: moda.
- Winsorización de outliers severos en:
 - *RevolvingUtilizationOfUnsecuredLines* (percentil 99).
 - *DebtRatio* (percentil 99.5).
- Estandarización de todas las variables usando `StandardScaler`.



Reducción de dimensionalidad (PCA)

- Aplicamos PCA sobre las 10 variables estandarizadas.
- Los primeros **6 componentes** explican $\approx$ **87.6 %** de la varianza.



Selección del número de clusters (K-Means)

- Se evaluaron $k = 2$ a 10 con dos criterios: método del codo y coeficiente de silhouette.
- Se seleccionó $k = 5$ por estabilidad e interpretabilidad.



Resultados


Resultados principales

La tabla resume las medias de cada variable agrupadas por temática para los 5 clusters.

Variable	0	2	3	4	1
Endeudamiento					
Revolving Utilization	0.107	0.690	0.260	0.277	1.000
Debt Ratio	131.7	92.7	37.2	3305.2	6.76
Morosidad					
30–59 días	0.121	0.389	0.286	0.245	97.96
60–89 días	0.023	0.226	0.052	0.050	97.96
90+ días	0.023	0.245	0.043	0.050	97.96
Actividad crediticia					
Líneas abiertas	7.94	5.23	12.24	10.05	0.01
Préstamos inmob.	0.70	0.44	1.89	1.78	0.00
Ingreso y demografía					
Ingreso mensual	5913	4789	9229	5124	3602
Edad	62.5	40.9	48.9	53.4	36.1
Dependientes	0.18	0.66	1.74	0.40	0.00

Perfiles financieros: gráfico de radar

Perfiles de Clientes - 4 Clusters (Estandarizado)



Interpretación de los perfiles identificados

- **Cluster 0: Estables y conservadores**

Baja morosidad, baja utilización del crédito y edad promedio más alta.

- **Cluster 2: Uso intensivo del crédito**

Mayor utilización del crédito, más dependientes y vulnerabilidad ante cambios en ingresos.

- **Cluster 3: Alta capacidad económica**

Ingresos más altos, muchas líneas de crédito y varios préstamos inmobiliarios, con morosidad baja.

- **Cluster 4: Sobreendeudados**

DebtRatio extremadamente elevado: gran parte del ingreso se destina al pago de deudas.

- **(Cluster 1: Riesgo extremo, no mostrado en radar)**

Morosidad muy alta y casi ninguna línea activa; se trata como outlier en algunas visualizaciones.

Conclusiones

- La segmentación reveló **cuatro perfiles financieros claros** en la población: estables, vulnerables, alta capacidad y sobreendeudados.
- El uso combinado de **PCA + K-Means** permitió capturar la estructura real del conjunto y separar patrones que no son visibles directamente en las variables originales.
- El preprocesamiento resultó clave: sin imputación, winsorización y escalado, los resultados habrían sido inestables o poco interpretables.
- La metodología mostró que los datos financieros contienen **patrones latentes** que pueden ser útiles para análisis de riesgo u orientación de estrategias crediticias.
- Como siguiente paso, sería valioso comparar esta segmentación con métodos alternativos y analizar cómo evolucionan los perfiles en datos longitudinales.