

Centro de Investigación en
Matemáticas

Introducción a la
Ciencia de Datos



Segmentación de Clientes por Perfil de Endeudamiento

Debany Jazmín Hernández Camacho

Introducción

La segmentación de clientes es una herramienta central en el análisis moderno de datos financieros, pues permite distinguir entre individuos con bajo riesgo, perfiles estables y usuarios con mayor probabilidad de presentar dificultades en el pago de sus obligaciones



Financieramente, cada cliente combina distintos niveles de:

- Ingresos,
- Uso del crédito,
- Historial de morosidad,
- Carga financiera,
- Número de dependientes.

Se trabajó con la base de datos **Give Me Some Credit**, que recopila información financiera y demográfica de aproximadamente 150,000 clientes. Cada registro resume la situación crediticia de un cliente mediante variables relacionadas con ingreso, endeudamiento, uso del crédito y comportamiento de pago.

Objetivo: Identificar, sin etiquetas previas, perfiles de clientes a partir de sus características crediticias.

Entonces, surgen las siguientes preguntas:

- ¿Qué caracteriza a los clientes menos riesgosos?
- ¿Qué patrones de endeudamiento o morosidad distinguen a los grupos más vulnerables?
- ¿Cómo se relacionan variables como ingresos, utilización de crédito y número de dependientes con el comportamiento crediticio?



	SeriousDlqin 2yrs	RevolvingUtili zationOfUnse	age	NumberOfTi me30-	DebtRatio	MonthlyInco me	NumberOfOp enCreditLines	NumberOfTi mes90DaysL	NumberRealE stateLoansOr	NumberOfTi me60-	NumberOfDe pendents
1	1	0.76612661	45	2	0.80298213	9120	13	0	6	0	2
2	0	0.95715102	40	0	0.1218762	2600	4	0	0	0	1
3	0	0.65818014	38	1	0.08511338	3042	2	1	0	0	0
4	0	0.23380978	30	0	0.03604968	3300	5	0	0	0	0
5	0	0.9072394	49	1	0.0249257	63588	7	0	1	0	0
6	0	0.21317868	74	0	0.37560697	3500	3	0	1	0	1
7	0	0.30568247	57	0	5710	NA	8	0	3	0	0
8	0	0.75446365	39	0	0.20994002	3500	8	0	0	0	0

Variable	Descripción
SeriousDlqin2yrs	Indica si el cliente tuvo morosidad grave (90+ días) en los próximos dos años.
RevolvingUtilizationOfUnsecuredLines	Proporción de uso de líneas de crédito no aseguradas (tarjetas). Valores altos indican uso intenso o al límite.
age	Edad del cliente en años.
NumberOfTime30-59DaysPastDueNotWorse	Número de veces con atrasos de 30–59 días.
DebtRatio	(Deuda mensual + gastos) / Ingreso mensual. Mide la carga financiera del cliente.
MonthlyIncome	Ingreso mensual declarado.
NumberOfOpenCreditLinesAndLoans	Número total de líneas de crédito y préstamos abiertos.
NumberOfTimes90DaysLate	Número de atrasos graves (90+ días) del cliente.
NumberRealEstateLoansOrLines	Número de préstamos o líneas inmobiliarias (hipotecas, etc.).
NumberOfTime60-89DaysPastDueNotWorse	Número de veces que ha estado entre 60–89 días de atraso.
NumberOfDependents	Cantidad de dependientes económicos declarados.



Preprocesamiento de los datos



1. Limpieza inicial

- Eliminación de 609 duplicados
- Eliminación de edad=0

2. Imputación de valores faltantes

- MonthlyIncome: ~5,400 valores faltantes → mediana
- NumberofDependents: moda (discreta y concentrada en 0-2)

3. Control de outliers (winsorización)


- RevolvingUtilizationOfUnsecuredLines → truncado en el percentil 99
- DebtRatio → truncado en el percentil 99.5 (outliers más severos)

4. Estandarización

- Todas las variables transformadas con StandardScaler.
- Cada variable queda con media 0 y varianza 1

Reducción de dimensionalidad

Aplicamos PCA sobre las 10 variables estandarizadas.




Los primeros 6 componentes explican ≈ 87.6 de la varianza

Selección del número de clusters (K-Means)


Método del codo:

- Se evaluaron valores de k entre 2 a 10.
- La curva comienza a estabilizarse alrededor de k=5.



Coefficiente de Silhouette

- Máximo en k=2 pero,
- Valores consistentes y estables entre k=3 y k=8





Resultados principales

Variable	Cluster 0	Cluster 2	Cluster 3	Cluster 4	Cluster 1
Endeudamiento y uso de crédito					
Revolving Utilization	0.107	0.69	0.26	0.277	1
Debt Ratio	131.673	92.73	37.194	3305.179	6.764
Morosidad (frecuencia de atrasos)					
30–59 días tarde	0.121	0.389	0.286	0.245	97.956
60–89 días tarde	0.023	0.226	0.052	0.05	97.956
90+ días tarde	0.023	0.245	0.043	0.05	97.956
Actividad crediticia					
Líneas abiertas	7.937	5.226	12.237	10.049	0.009
Préstamos inmobiliarios	0.701	0.442	1.887	1.778	0
Ingresos y características demográficas					
Ingreso mensual	5912.836	4789.837	9229.359	5124.065	3602.027
Edad	62.498	40.893	48.875	53.395	36.071
Dependientes	0.178	0.664	1.739	0.4	0
Tamaño del cluster					
Conteo	58054	40646	39604	10861	225
Porcentaje (%)	38.861	27.208	26.51	7.27	0.151

Gráfico de radar

Comparación visual de las medias normalizadas de cada cluster



Segmentación de Clientes



Cluster 0 (Perfil estable y conservador)

- Uso muy bajo del crédito
- Morosidad casi nula
- Edad promedio alta
- Ingresos moderados
- Comportamiento prudente



Segmentación de Clientes



Cluster 2 (Perfil vulnerable con uso intensivo del crédito)



- Alta utilización del crédito para cubrir gastos
- Mayor número de dependientes
- Morosidad ligera pero frecuente
- Edad menor y recursos financieros limitados
- Riesgo potencial de deterioro ante cambios económicos



Segmentación de Clientes

Cluster 3 (Perfil consolidado con alta capacidad económica)

- Ingresos significativamente altos
- Muchas líneas de crédito activas
- Varios préstamos inmobiliarios
- Morosidad baja y buen manejo del crédito
- Perfil sólido, estable y financieramente robusto



Segmentación de Clientes

Cluster 4 (Perfil sobre endeudado)

- DebtRatio extremadamente elevado
- Actividad crediticia moderada, pero cargas muy altas
- Ingresos no suficientes para cubrir compromisos
- Nivel claro de estrés financiero
- Necesita gestión o medidas de alivio crediticio



Conclusiones:

- La combinación de PCA + KMeans permitió identificar perfiles financieros claros y coherentes.
- Los clusters revelan comportamientos reales: estabilidad, vulnerabilidad, capacidad económica y sobreendeudamiento.
- La segmentación facilita la comprensión del riesgo financiero sin depender de etiquetas previas.

Limitaciones:

- La base de datos es transversal, por lo tanto no captura evolución del comportamiento financiero.
- Las variables son exclusivamente numéricas, por lo que no podemos considerar factores cualitativos (empleo, patrimonio, historial detallado).
- No se validó la segmentación con métricas alternas (no hay “verdaderos perfiles” para comparar el modelo)

Trabajo a futuro:

- Probar otros algoritmos de clustering.
- Incorporar datos longitudinales para ver transiciones entre perfiles
- Evaluar la utilidad práctica de los clusters en tareas reales (predicción de morosidad, estrategias personalizadas de riesgo)